

Você vai ser responsável por me ajudar a desenhar backtests para o projeto abaixo. O objetivo, nesse primeiro momento, é abrir o horizonte de possibilidades, com uma descrição breve de cada um, e a medida que escolhas forem sendo feitas vamos entrando nos detalhes técnicos e fundamentação arquitetural dos backtests.

Atualmente, faço parte do projeto Investimento por Amizade, onde o desafio é construir rede de investidores de um grande banco brasileiro e encontrar os grupos dos mais influentes. Do ponto de vista técnico, temos uma base de grafo grande (30MM nós e 150MM de arestas). Nela agregamos informações de captação líquida (movimentação de crédito e débito de produtos de investimentos) e de transação de TedPix. Ambas, usando suavização Bayesiana, são usadas para ponderar as arestas com uma probabilidade de influência. Na ausência de dados empíricos para tais valores, utilizamos métricas de centralidade para estimar esse valor. Posteriormente, aplicamos algoritmo de maximização de influência que produz lista das sementes ideais com spread e distância média aos influenciados individualmente. Além disso, produz lista dos influenciados, com probabilidade de ser influenciado junto com o influenciador principal. A lista de sementes ideais também produz um ranking de influencia baseado no ganho marginal.

Extraímos do grafo de 30MM de nós e 150MM de arestas os 90k mais influentes. Como resultado, temos

- 1) diversas métricas de centralidade/comunidades calculadas para todo o grafo
- 2) para os influenciadores spread/distância média, ranking de influência
- 3) para os influenciados probabilidade de ser influenciado pelo seed-set junto com o influenciador mais provável.

Agora é hora de provar valor com backtests. A liderança quer ver bignumbers relacionados ao projeto e tenho até dia 23 para mostrá-los.

Fala, Hugo. Excelente desafio. Lidar com um grafo de 30 milhões de nós e 150 milhões de arestas não é trivial, e aplicar maximização de influência com suavização Bayesiana em cima de captação líquida e Ted/Pix é uma abordagem arquitetural de altíssimo nível.

Como a liderança precisa ver *big numbers* até o dia 23, o foco agora é **tempo de execução vs. impacto visual**. Backtests em grafos dessa magnitude exigem *joins* temporais pesados (provavelmente no PySpark), então precisamos de estratégias que sejam

computacionalmente viáveis para essa janela curta e que traduzam métricas de rede (spread, centralidade) em linguagem de negócios (R\$, Captação, Retenção).

Aqui estão quatro horizontes de backtest para abirmos o leque, do mais rápido de executar ao mais complexo.

1. Backtest Estático de AUM (Assets Under Management) sob Influência

Este é o teste mais rápido e o que gera o *big number* mais imediato para a liderança. Não exige análise de série temporal profunda, apenas um *snapshot* histórico recente.

- **A Mecânica:** Pegamos o mês de fechamento mais recente. Calculamos o volume total de investimentos (ou captação líquida positiva) das 90k sementes e somamos ao volume da base de influenciados diretos (ponderado pela probabilidade de influência que você já calculou).
- **O Big Number:** *"R\$ X Bilhões da nossa base de captação estão sob o guarda-chuva de influência de apenas 90 mil clientes (0.3% da base)."*
- **Por que funciona:** Mostra o "tamanho do risco/oportunidade" de forma tátil. Valida que o algoritmo não escolheu 90k pessoas isoladas, mas sim verdadeiros *hubs* de capital.

2. Backtest de Contágio Temporal (Adoção de Produtos)

Aqui provamos a causalidade da rede. O objetivo é mostrar que quando uma semente se move, a rede ecoa.

- **A Mecânica:** Escolhemos um evento histórico claro ocorrido há 3-6 meses (ex: uma forte campanha de LCA/LCI, ou um período de alta movimentação na renda fixa). Isolamos as sementes que adotaram o produto primeiro (Tempo t_0). Em seguida, medimos a taxa de adoção desse mesmo produto entre os seus influenciados nos 30 a 60 dias seguintes (t_1).
- **O Big Number:** *"Clientes influenciados por nossas sementes têm X% mais chance de aderir a um novo produto de investimento em até 45 dias após a semente investir."*
- **Por que funciona:** Valida o *spread* calculado pelo algoritmo de maximização de influência com dados empíricos de conversão.

3. Backtest de Defesa de Carteira (O Efeito Dominó de Saída)

A liderança bancária é altamente motivada por aversão à perda. Provar que a rede prevê saídas de capital é um argumento matador.

- **A Mecânica:** Olhamos para uma janela histórica (ex: últimos 6 meses). Identificamos sementes que tiveram forte captação líquida negativa (tiraram dinheiro do banco). Avaliamos o comportamento da sua sub-rede de influenciados nos meses subsequentes. Houve evasão de capital em cascata?
- **O Big Number:** *"Quando um influenciador reduz sua posição, observamos uma fuga de R\$ Y Milhões na sua rede conectada nas semanas seguintes. O monitoramento prévio desses 90k clientes pode reter Z milhões anualmente."*

- **Por que funciona:** Dá um caso de uso imediato de mitigação de risco e CRM preditivo.

4. Backtest de Proxy A/B (Lift Orgânico)

Este testa o ganho marginal real das suas sementes em comparação com o resto da base.

- **A Mecânica:** Criamos dois grupos historicamente: o Grupo A (os influenciados pela sua lista de sementes, com alta probabilidade de influência) e o Grupo B (um grupo de controle "look-alike", com perfil demográfico e de saldo similar, mas fora das comunidades de influência). Medimos o crescimento orgânico da captação líquida de ambos ao longo de 6 meses.
- **O Big Number:** *"O efeito de rede gera um 'lift' orgânico de X% na captação líquida; clientes em comunidades altamente influenciadas aportam R\$ Y a mais em média do que clientes com o mesmo perfil isolados na rede."*
- **Por que funciona:** Justifica o custo e a complexidade de manter uma arquitetura de grafos, isolando o "efeito amizade/influência" do mero crescimento inercial do banco.

Qual desses caminhos soa mais promissor para apresentarmos até o dia 23?

Se precisarmos de vitórias rápidas, sugiro atacarmos o **1 (AUM sob Influência)** para garantir o *big number* do slide de abertura, e escolhermos ou o **2 (Contágio)** ou o **3 (Defesa)** para rodar o processamento pesado no PySpark e mostrar a dinâmica da rede na prática.

Excelente questionamento. O seu instinto está corretíssimo ao olhar para esse volume de 17 milhões de influenciados e ver um potencial problema de ruído.

A razão para ponderar pela probabilidade de influência não é apenas matemática, mas fundamentalmente de **credibilidade executiva e atribuição de valor**. Se apresentarmos o AUM (Assets Under Management) total de 17 milhões de clientes, o número será estratosférico, e a liderança inevitavelmente questionará a validade da afirmação de que 90k pessoas "controlam" todo esse montante.

Aqui estão os três motivos técnicos e de negócios para usar a probabilidade como peso nesse backtest:

1. O Cálculo do Valor Esperado (Atribuição Justa)

A ponderação transforma o saldo total em um **AUM Atribuível à Influência** (um Valor Esperado estatístico). Se um influenciado possui R\$ 100.000,00 aplicados, mas a probabilidade de ele ter tomado essa decisão com base na semente é de apenas 5%, nós

assumimos que apenas R\$ 5.000,00 da carteira dele são um "risco de rede" ou "capital influenciado". Isso blindo o seu modelo contra críticas de superestimação.

2. O Efeito de Amortecimento da Cauda Longa (Lidando com os 17MM)

Como você mencionou, muitos desses 17 milhões têm uma probabilidade muito baixa. Ao multiplicar o saldo de captação pela probabilidade, o modelo naturalmente penaliza o ruído dessa cauda longa. Aquele cliente que caiu na comunidade por uma aresta muito fraca de Ted/Pix, com 0,5% de probabilidade, terá seu impacto financeiro reduzido a quase zero no somatório final, deixando o "Big Number" ser puxado pelos nós que realmente sofrem forte influência.

3. Teste de Sensibilidade (Thresholding)

Como alternativa (ou complemento) à ponderação direta, ter a probabilidade permite que você apresente o "Big Number" em cenários (cortes). Você pode filtrar o ruído e dizer à liderança:

- *"Considerando apenas a nossa rede primária (clientes com probabilidade de influência > 40%), temos R\$ X bilhões diretamente conectados a essas 90k sementes."*
- Isso reduz o universo de 17MM para um núcleo duro muito mais acionável e fácil de justificar para as áreas de negócios.

Sugestão de Execução para este Backtest:

Dado que o prazo é dia 23, você pode calcular duas métricas rapidamente a partir das tabelas que já tem:

1. **AUM Total Diretamente Influenciado:** $\sum (\text{Saldo do Influenciado}) \times (\text{Probabilidade de Influência})$.
2. **AUM de Alta Influência (Threshold):** Somatório do saldo integral, mas cortando a base apenas para influenciados com $P > 0.3$ (ou o quartil superior da sua distribuição de probabilidade).

O que acha de seguirmos com o cálculo do Valor Esperado para o slide principal e levarmos um corte de "Alta Probabilidade" no apêndice para caso eles queiram focar em um grupo menor para campanhas imediatas?

Perfeito. Fazer o Backtest 1 via Athena vai te garantir o *Big Number* de forma rápida e elegante.

Sobre o Backtest 2, você tocou no ponto central do problema de atribuição causal em redes. Se avaliarmos a base inteira de influenciados quando apenas 5% das sementes "ativaram" o gatilho (adotaram o produto), o efeito real do contágio será diluído e mascarado pelos 95% de sementes inativas. Rodar o algoritmo de maximização novamente *apenas* para esses 4.500 early adopters seria custoso e talvez inviável para o dia 23.

A solução arquitetural elegante para isso está em um detalhe precioso que você mencionou no seu primeiro escopo: **você já produz a lista de influenciados com o influenciador principal mapeado**. Essa é a chave de ouro para resolver o problema usando apenas SQL/PySpark sem reprocessar o algoritmo de influência.

Aqui está o desenho de como isolar o contágio usando um **Teste de Lift por Exposição Direta**:

O Desenho do Backtest de Causalidade (Lift de Contágio)

Passo 1: Definir o Tempo e o Gatilho (\$t_0\$)

Defina a janela de "Early Adopters". Por exemplo, os primeiros 15 ou 30 dias da campanha de renda fixa no início de 2025. Isole os ~4.500 *seeds* (dos 90k) que aportaram no produto nessa janela. Estes são os seus "Pacientes Zero".

Passo 2: Criar o Grupo de Tratamento (Os Expostos)

Vá na sua tabela de influenciados gerada para a época. Filtre apenas os clientes cujo **influenciador_principal** esteja dentro da lista de Pacientes Zero.

- *Dica de Sintonia*: Para um sinal mais forte, você pode aplicar um corte aqui também (ex: pegar apenas expostos com probabilidade de influência > 15%).
- Estes são os clientes que "viram/sentiram" o líder da sua comunidade investir.

Passo 3: Criar o Grupo de Controle Look-Alike (Os Não-Expostos)

Para provar que a conversão foi por influência e não apenas pelo mercado, pegue os influenciados cujo **influenciador_principal NÃO investiu** no \$t_0\$.

- *Por que isso é poderoso?* Porque você está comparando pessoas que têm a mesma topologia de rede (ambos são influenciados de comunidades fortes), mas com a diferença vital: um teve a semente ativada, o outro não. Isso isola o "efeito da campanha" do "efeito do influenciador".

Passo 4: Medir a Conversão no Horizonte (\$t_1\$)

Olhe para a janela de tempo *após* o \$t_0\$ (ex: dias 31 a 90 da campanha). Qual percentual do Grupo de Tratamento adotou a renda fixa? Qual percentual do Grupo de Controle adotou?

Passo 5: O Cálculo do Lift (O Big Number)

Você fará a razão entre as conversões:

$$\text{Lift} = \left(\frac{\text{Taxa de Conversão do Tratamento}}{\text{Taxa de Conversão do Controle}} \right) - 1$$

O que mostrar para a Liderança?

O slide fica extremamente narrativo e com forte embasamento matemático:

"Identificamos 4.500 influenciadores que aderiram rapidamente à campanha de Renda Fixa de 2025. Monitoramos a rede de clientes onde esses

*influenciadores eram a força principal. O resultado: um cliente conectado a um influenciador ativo teve **X% mais probabilidade** de aderir à mesma campanha nos 60 dias seguintes, em comparação a clientes de perfil similar cujos influenciadores não participaram."*

Vantagem Técnica para o Prazo:

Se você já vai reconstruir o grafo do início de 2025 e rodar o modelo de influência para achar as 90k sementes da época, o resto desse backtest é puramente manipulação de Dataframe (PySpark) com *joins* de datas de transação, sem necessidade de recalculer pesos dinâmicos na rede.

Faz sentido essa segmentação usando o `influenciador_principal` como chave para isolar o grupo de tratamento?

O Backtest 3 é possivelmente o que vai gerar mais impacto na alta gestão. O mercado financeiro é naturalmente guiado pela aversão à perda, e provar que a sua rede serve como um **"Radar de Alerta Antecipado"** para evasão de capital (churn ou grandes resgates) justifica o projeto por si só.

A beleza tática aqui é que você pode reaproveitar **exatamente a mesma base histórica (grafo e sementes)** que você vai reconstruir para o Backtest 2, invertendo apenas o sinal da métrica de negócio: em vez de adoção de produto, medimos a fuga de capital.

Aqui está o desenho estrutural para o **Backtest de Efeito Dominó (Defesa de Carteira)**:

O Desenho do Backtest de Saída de Capital

Passo 1: O Gatilho de Fuga (\$t_0\$)

Usando o grafo histórico, isole as sementes (dentre as 90k) que tiveram uma **captação líquida fortemente negativa** num mês específico. Você pode definir esse corte como as sementes no quartil inferior de captação (os que mais tiraram dinheiro) ou aqueles que zeraram a posição no banco. Estes são os seus "Nós em Fuga".

Passo 2: O Raio de Explosão (Grupo de Risco)

Cruze esses "Nós em Fuga" com a tabela de influenciados, filtrando novamente pelo `influenciador_principal`. Estes são os clientes que estão sob risco iminente de contágio negativo.

- *Dica de Sintonia:* Para maximizar o "Big Number", você pode focar nos influenciados com alta probabilidade de influência ou menor distância para a semente.

Passo 3: O Grupo de Controle da Estabilidade

Para provar que a fuga foi um efeito de rede e não uma questão macroeconômica (como uma queda na Selic fazendo todo mundo sacar da renda fixa), pegue os influenciados cujos influenciadores principais mantiveram o saldo estável ou positivo no mesmo período \$t_0\$.

Passo 4: A Medida do Dano (A Janela \$t_1, t_2\$)

Monitore a captação líquida do Grupo de Risco e do Grupo de Controle nos 30, 60 e 90 dias após a saída do influenciador.

- Nós queremos calcular duas coisas:
 1. **Aceleração de Resgate:** O Grupo de Risco sacou mais dinheiro (proporcionalmente) que o Grupo de Controle?
 2. **O Volume Sangrado:** Qual foi a soma total de R\$ (captação negativa) perdida nesse Grupo de Risco nesses meses subsequentes?

O Big Number para a Liderança

Você chegará na reunião de apresentação com dois números absurdamente poderosos:

O Diagnóstico: *"Quando um dos nossos 90k influenciadores reduz drasticamente sua posição, a sua rede direta de influenciados tem uma probabilidade **X% maior** de evasão de capital nos 60 dias seguintes em relação à média do banco."*

A Oportunidade Financeira (O número de ouro): *"No período analisado, o efeito cascata gerado pela saída desses líderes de rede resultou numa evasão de **R\$ Y Milhões**. Se tivéssemos acionado nosso time de assessoria/gerentes para atuar na retenção dessas sementes no D-0, poderíamos ter protegido essa volumetria na carteira."*

Vantagem de Execução

Como você já vai ter a tabela de influenciados com o influenciador_principal e a probabilidade calculada para o Backtest 2, esse Backtest 3 é basicamente uma nova query no Athena ou um notebook PySpark simples focado em métricas de saldo e captação (crédito vs débito), sem necessidade de rodar algoritmos pesados de grafos novamente.

Tendo definido esses três backtests (AUM Estático, Contágio de Produto e Defesa de Carteira), como você prefere estruturar a apresentação para o dia 23: focar em um deles com extrema profundidade técnica, ou mostrar a visão macro dos três com os resultados iniciais para provar a versatilidade do grafo?